Étiquette :

- **Domaine** : Faune sauvage — Détection automatisée par caméra
- **Type de données** : Données de prédiction IA (pièges photographiques)
- **Lieu** : Massif des Bauges (PNR) & Massif du Mont-Blanc (Chamonix)
- **Source** : CREA Mont-Blanc / DeepFaune (CNRS)
- **Période** : 2017 – 2024 (Mont-Blanc) | 2023 – 2024 (Bauges)
- **Auteur** : Abdassalam
- **Version** : 1.0

Table des matières

Introduction **3**
0.1 Contexte du Projet . . . 3
0.2 Objectifs de la Documentation . . . 3

1 Informations Générales **4**
1.1 Vue d'ensemble des Sources . . . 4
1.2 Dictionnaire de Données . . . 4
1.3 Étendue Spatiale . . . 5
1.4 Étendue Temporelle . . . 6

2 Analyse par Dossier **7**
2.1 Dossier : Bauges . . . 7
2.1.1 Attributs existants . . . 7
2.1.2 Analyse par attribut . . . 7
2.1.2.1 Attribut : Identifiant . . . 7
2.1.2.1.1 Informations générales . . . 7
2.1.2.1.2 Problèmes de qualité . . . 7
2.1.2.2 Attribut : Temporel . . . 7
2.1.2.2.1 Informations générales . . . 7
2.1.2.2.2 Problèmes de qualité . . . 8
2.1.2.3 Attribut : Prédiction . . . 8
2.1.2.3.1 Informations générales . . . 8
2.1.2.3.2 Problèmes de qualité . . . 9
2.1.2.4 Attribut : Comptage . . . 9
2.1.2.4.1 Informations générales . . . 9
2.1.2.4.2 Problèmes de qualité . . . 10
2.1.2.5 Attribut : Séquence . . . 10
2.1.2.5.1 Informations générales . . . 10
2.1.2.5.2 Problèmes de qualité . . . 10
2.2 Dossier : Mont_Blanc . . . 11
2.2.1 Attributs existants . . . 11
2.2.2 Analyse par attribut . . . 11
2.2.2.1 Attribut : Identifiant . . . 11
2.2.2.1.1 Informations générales . . . 11
2.2.2.1.2 Problèmes de qualité . . . 12
2.2.2.2 Attribut : Temporel . . . 12
2.2.2.2.1 Informations générales . . . 12
2.2.2.2.2 Problèmes de qualité . . . 13
2.2.2.3 Attribut : Prédiction . . . 13
2.2.2.3.1 Informations générales . . . 13
2.2.2.3.2 Problèmes de qualité . . . 14
2.2.2.4 Attribut : Comptage . . . 14
2.2.2.4.1 Informations générales . . . 14
2.2.2.4.2 Problèmes de qualité . . . 14
2.2.2.5 Attribut : Séquence . . . 15

2.2.2.5.1 Informations générales 15
2.2.2.5.2 Problèmes de qualité 15

3 Synthèse des Problèmes de Qualité **16**
3.1 Attribut : Identifiant 16
3.1.1 Hétérogénéité des noms entre Bauges et Mont_Blanc 16
3.1.2 Recommandation ETL 16
3.2 Attribut : Localisation 16
3.2.1 Coordonnées manquantes pour les Bauges 16
3.2.2 Caméras orphelines (hors périmètre CREA) 16
3.2.3 Recommandation ETL 17
3.3 Attribut : Temporel 17
3.3.1 Fuseaux horaires (UTC vs heure locale) 17
3.3.2 Recommandation ETL 17
3.4 Attribut : Prédiction 17
3.4.1 Hétérogénéité des taxonomies entre modèles 17
3.4.2 Classes non-biologiques 18
3.4.3 Recommandation ETL 18
3.5 Attribut : Comptage 18
3.5.1 Valeurs manquantes sur count_second 18
3.5.2 Recommandation ETL 18
3.6 Attribut : Séquence 18
3.6.1 Séquences anormalement longues (animaux stationnaires) 19
3.6.2 Recommandation ETL 19

Introduction

0.1 Contexte du Projet

Ce document constitue la documentation technique des données de détection de faune sauvage issues du projet **DeepFaune**, développé par le CNRS. Ces données sont collectées via des pièges photographiques (caméras à déclenchement infrarouge) déployés sur deux massifs montagneux :

— **Le Massif du Mont-Blanc (Chamonix) :** Géré par le Centre de Recherches sur les Écosystèmes d'Altitude (**CREA Mont-Blanc**), ce site dispose d'une couverture historique longue (2017–2024) et de coordonnées GPS précises pour chaque caméra.

— **Le Massif des Bauges (PNR) :** Site plus récent, dont les données couvrent la période 2023–2024. Les coordonnées GPS précises des caméras ne sont pas encore disponibles.

Les séquences d'images capturées sont analysées automatiquement par des algorithmes d'intelligence artificielle pour identifier les espèces animales présentes.

0.2 Objectifs de la Documentation

Objectifs

Cette documentation vise à fournir une référence complète pour l'alimentation du pipeline ETL à travers quatre axes :

1. **Description des sources :** Présenter la structure et le contenu des données issues de DeepFaune.
2. **Analyse attribut par attribut :** Documenter les informations générales et les problèmes de qualité pour chaque colonne.
3. **Synthèse transversale :** Croiser les problèmes identifiés entre les dossiers Bauges et Mont_Blanc.
4. **Recommandations ETL :** Proposer des règles de gestion concrètes pour sécuriser l'intégration des données.

1 | Informations Générales

1.1 Vue d'ensemble des Sources

Les données documentées ici proviennent d'une unique source logique : le dossier **CREA** / **DeepFaune** du serveur FTP interne. Ce dossier est organisé en deux sous-dossiers correspondant aux deux zones d'étude.

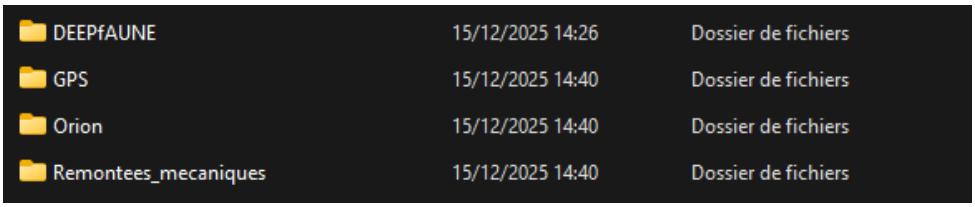

DEEPfAUNE	15/12/2025 14:26	Dossier de fichiers
GPS	15/12/2025 14:40	Dossier de fichiers
Orion	15/12/2025 14:40	Dossier de fichiers
Remontees_mecaniques	15/12/2025 14:40	Dossier de fichiers

Figure 1.1 : Arborescence du dossier CREA

Dossier	Modèle IA	Nb Prédictions	Nb Caméras
Mont_Blanc	MegaDetector V6 (MDV6)	116 144	49
Bauges	MegaDetector V5 (MDV5)	5 956	18

Fonctionnement de DeepFaune

DeepFaune utilise une architecture IA en deux étapes :

1. **Détection (YOLOv8) :** Localisation et détourage des sujets (animaux, humains, véhicules).
2. **Identification (CNN) :** Un réseau de neurones convolutif identifie l'espèce précise.

Les caméras capturent des **rafales d'images** (intervalle max 3 secondes). DeepFaune analyse la séquence entière via un **vote majoritaire** pour fiabiliser la prédiction. Le résultat gagnant devient `prediction_first` et le second `prediction_second`.

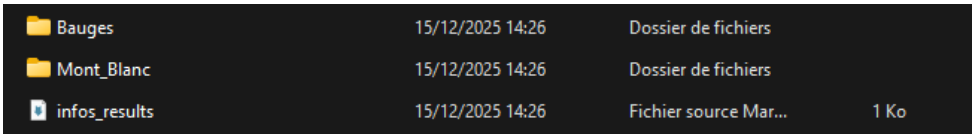

Bauges	15/12/2025 14:26	Dossier de fichiers	
Mont_Blanc	15/12/2025 14:26	Dossier de fichiers	
infos_results	15/12/2025 14:26	Fichier source Mar...	1 Ko

Figure 1.2 : Schéma de fonctionnement de l'algorithme DeepFaune

1.2 Dictionnaire de Données

COLONNE	DESCRIPTION / RÔLE	EXEMPLE	CARDINALITÉ
Camera_trap	Identifiant unique du dispositif de capture. Le préfixe indique souvent la zone géographique et l'altitude.	*loriaz1900Ouest, bau02*	MB : 49 Bauges : 18
Date	Horodatage précis du déclenchement. Format ISO 8601. Essentiel pour les séries temporelles.	*2021-06-15 08 :34 :12*	Période : 2017–2024 > 100k lignes
prediction_first	Espèce ou objet identifié majoritairement dans la séquence par l'IA (vote majoritaire).	*chamois, vache, humain, vide*	MB : 26 classes Bauges : 22
prediction_second	Deuxième classification la plus probable (hésitation entre deux espèces ou présence simultanée).	*vide, chien, blaireau*	MB : 28 classes Bauges : 22
count_first	Nombre d'individus distincts détectés pour l'espèce de la première prédiction (ex : un troupeau de 3 chamois).	*1, 2, 3...*	MB : 22 val. Bauges : 9 val.
count_second	Nombre d'individus distincts pour l'espèce de la seconde prédiction.	*1, 2...*	MB : 5 val. Bauges : 14 val.
seq_first	Nombre d'images dans la séquence confirmant la prédiction principale.	*30, 60, 288...*	Max MB : 60 Max Bauges : 30
seq_second	Nombre d'images dans la séquence confirmant la prédiction secondaire.	*5, 12...*	Variable

1.3 Étendue Spatiale

L'analyse de la localisation des dispositifs révèle une disparité importante entre les deux zones d'étude.

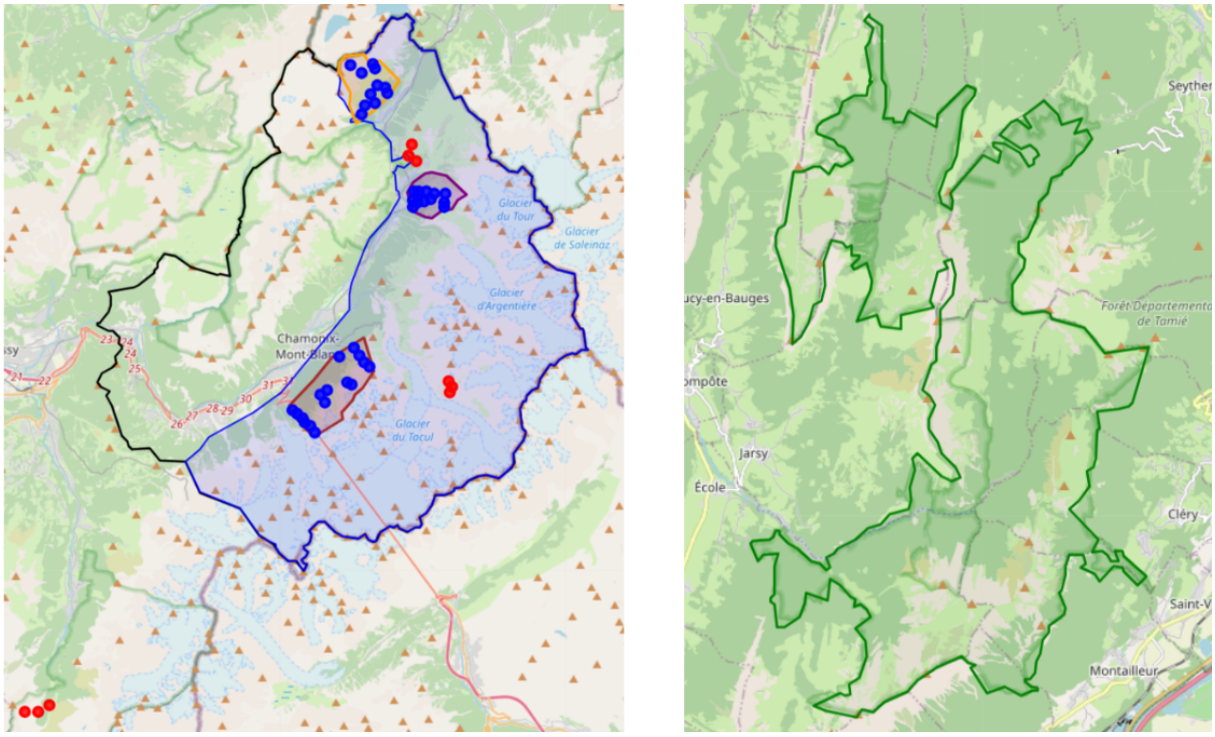

Légende :

Limite du massif des Bauges	Secteurs DeepFaune (Zone CREA)
Caméras hors CREA	Station CREA – Plan de l'Aiguille
Caméras dans le périmètre	Station CREA – Loriaz
	Station CREA – Peclerey

FIGURE 1.1 – Données géographiques pour les zones Mont-Blanc et Bauges

— **Mont-Blanc :** Les coordonnées précises (Latitude/Longitude) sont disponibles et exploitables pour les 49 caméras. Une partie des caméras est incluse dans les périmètres CREA (Loriaz, Peclerey, PlanAig), d'autres sont dites **orphelines**.

— **Bauges :** **Information manquante.** Seuls les toponymes (noms des stations) sont fournis. Il est impossible de situer exactement les caméras sur la carte sans table de correspondance.

1.4 Étendue Temporelle

Les jeux de données couvrent des périodes très inégales. Le jeu de données Mont-Blanc offre une profondeur historique près de **5 fois supérieure** à celui des Bauges.

Zone	Date Début	Date Fin	Durée Totale
Bauges	09/06/2023 10 :11 :41	15/11/2024 16 :12 :07	525 jours
Mont-Blanc	01/01/2017 23 :14 :25	03/12/2024 21 :56 :25	**2 892 jours**

2 | Analyse par Dossier

2.1 Dossier : Bauges

2.1.1 Attributs existants

Le dossier Bauges a été traité avec le modèle **MegaDetector V5 (MDV5)**. Il contient **5 956 prédictions** issues de **18 caméras** sur une période de 525 jours (juin 2023 – novembre 2024).

COLONNE	TYPE	PRÉSENT
Camera_trap	Catégoriel — Identifiant de la caméra	
Date	Temporel — Horodatage ISO 8601	
prediction_first	Catégoriel — Espèce principale détectée	
prediction_second	Catégoriel — Espèce secondaire détectée	
count_first	Numérique — Nombre d'individus (prédiction 1)	
count_second	Numérique — Nombre d'individus (prédiction 2)	
seq_first	Numérique — Nb d'images confirmant prédiction 1	
seq_second	Numérique — Nb d'images confirmant prédiction 2	

2.1.2 Analyse par attribut

2.1.2.1 Attribut : Identifiant

Colonnes traitées : **[Camera_trap]**

2.1.2.1.1 Informations générales Le dossier Bauges contient **18 caméras uniques**. Les identifiants suivent une convention de nommage courte, souvent préfixée par `bau` suivi d'un numéro ou d'un nom de lieu.

— Exemples : `bau02`, `bau03`, `bau26`, `baulife23`, `baulife24`

— Format : chaîne de caractères alphanumériques, sans séparateur standard.

2.1.2.1.2 Problèmes de qualité La convention de nommage des Bauges est **différente** de celle du Mont-Blanc, ce qui empêche toute jointure directe entre les deux sources sans table de mapping.

2.1.2.2 Attribut : Temporel

Colonnes traitées : **[Date]**

2.1.2.2.1 Informations générales

— **Format :** ISO 8601 — `AAAA-MM-JJ HH:MM:SS`

— **Plage temporelle :** Du `09/06/2023` au `15/11/2024` soit **525 jours**.

— La colonne est complète : **0% de valeurs manquantes**.

2.1.2.2.2 Problèmes de qualité Le fuseau horaire enregistré (UTC ou heure locale) n'est pas documenté dans les métadonnées. Une vérification est nécessaire avant intégration pour éviter des décalages temporels dans les analyses.

2.1.2.3 Attribut : Prédiction

Colonnes traitées : **[prediction_first, prediction_second]**

2.1.2.3.1 Informations générales Le modèle MDV5 identifie **22 classes** pour les Bauges via un système de **vote majoritaire** sur la séquence entière d'images :

— *Ongulés :* Bouquetin, Cerf, Chamois, Chevreuil, Sanglier, Vache, Mouton, Équidé.

— *Carnivores :* Loup, Renard, Chien, Blaireau, Mustélidé, Chat.

— *Petits Mammifères :* Marmotte, Écureuil, Lièvre, Micromammifère.

— *Autres :* Humain, Oiseau, Vide, Indéfini.

La classe **vide** domine les prédictions secondaires : l'animal entre ou sort du champ de vision, laissant des images vides que l'IA détecte correctement.

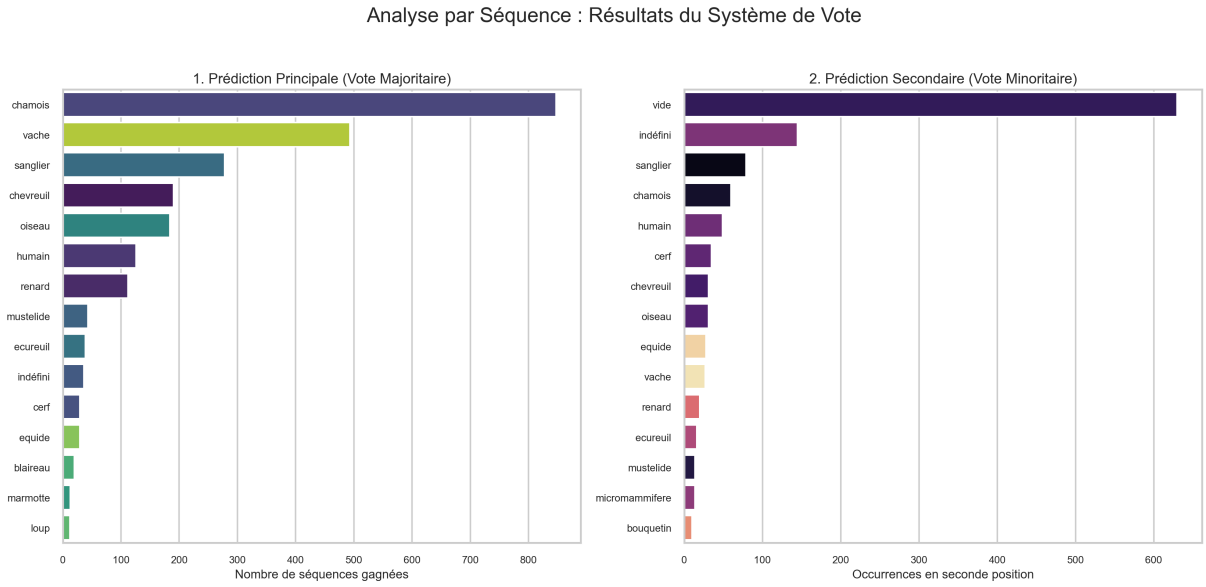

FIGURE 2.1 – Comparaison des prédictions principales et secondaires

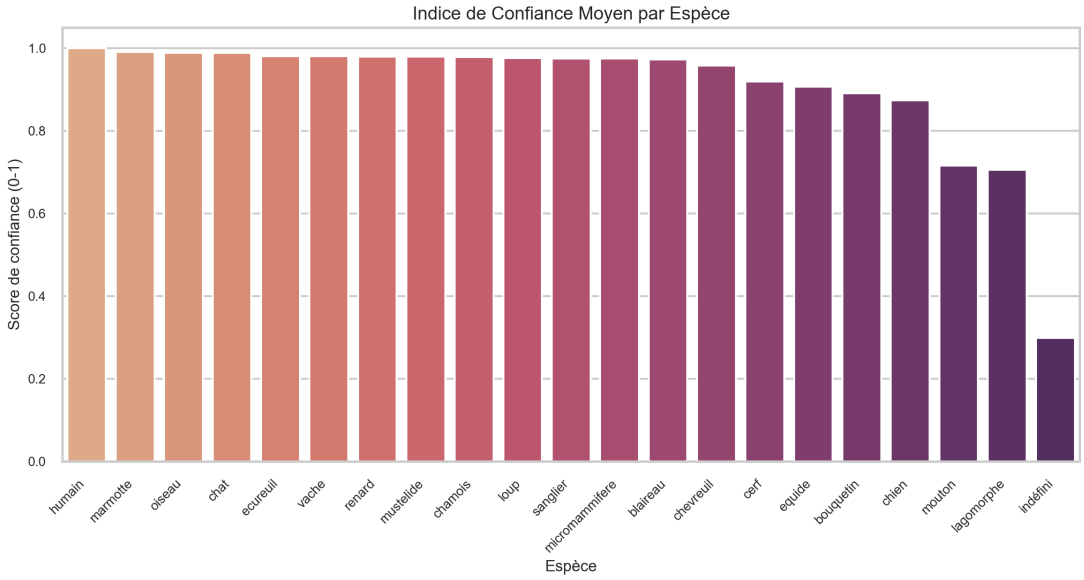

FIGURE 2.2 – Indice de confiance moyen par espèce

2.1.2.3.2 Problèmes de qualité

- **Classes manquantes :** Certaines espèces détectées par les modèles Mont-Blanc sont absentes des résultats Bauges : `lynx`, `genette`, `daim`, `chevre`, `vehicule`.
- **Scores de confiance faibles :** Les classes *Indéfini* et *Lagomorphe (Lièvre)* présentent un score inférieur à 0.75, nécessitant une validation humaine.
- **Scores excellents (> 0.95) :** Humain, Marmotte, Oiseau.

2.1.2.4 Attribut : Comptage

Colonnes traitées : **[count_first, count_second]**

2.1.2.4.1 Informations générales

- **count_first :** 9 valeurs distinctes pour les Bauges. Représente le nombre d'individus de l'espèce principale détectée.
- **count_second :** 14 valeurs distinctes. Absent lorsqu'il n'y a pas de prédiction secondaire.

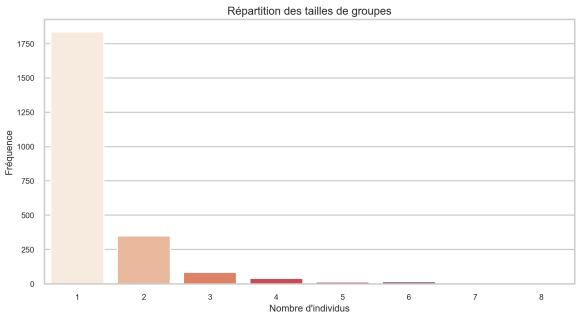

FIGURE 2.3 – Fréquence des tailles de groupes

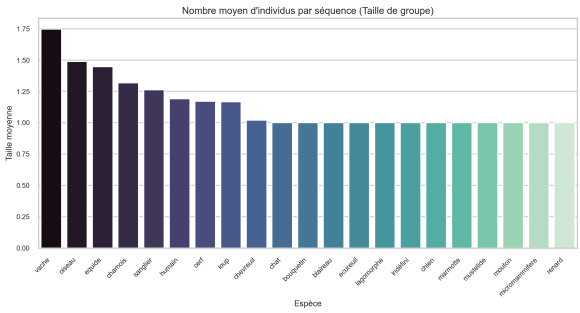

FIGURE 2.4 – Taille moyenne par espèce

La grande majorité des détections concerne des **individus solitaires**. Les espèces domestiques (Vache, Équidé) et certains oiseaux se déplacent en groupes plus grands (moyenne > 1.5).

2.1.2.4.2 Problèmes de qualité **count_second** contient des valeurs manquantes lorsque la prédiction secondaire est `vide`. Il faut distinguer une vraie absence de détection d'une valeur non renseignée.

2.1.2.5 Attribut : Séquence

Colonnes traitées : **[seq_first, seq_second]**

2.1.2.5.1 Informations générales

- **seq_first :** Nombre d'images confirmant la prédiction principale. Valeur maximale pour les Bauges : **30 images**.
- **seq_second :** Nombre d'images confirmant la prédiction secondaire. Absent si pas de second vote.

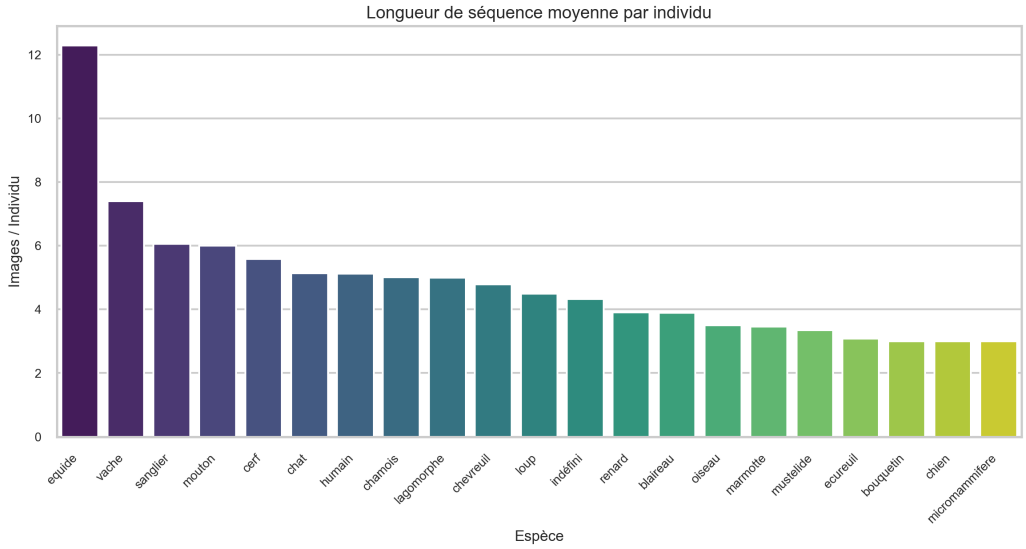

FIGURE 2.5 – Longueur moyenne des séquences (Images/Individu)

2.1.2.5.2 Problèmes de qualité Les espèces domestiques (Vache, Équidé) stationnent longtemps devant les caméras, générant des séquences longues et potentiellement des **doublons d'observation** pour un même événement.

2.2 Dossier : Mont_Blanc

2.2.1 Attributs existants

Le dossier Mont_Blanc a été traité avec le modèle **MegaDetector V6 (MDV6)**, retenu après comparaison avec DeepFaune (expérience du 16/12/2024). Il contient **116 144 prédictions** issues de **49 caméras** sur 2 892 jours.

COLONNE	TYPE	PRÉSENT
Camera_trap	Catégoriel — Identifiant de la caméra	
Date	Temporel — Horodatage ISO 8601	
prediction_first	Catégoriel — Espèce principale détectée	
prediction_second	Catégoriel — Espèce secondaire détectée	
count_first	Numérique — Nombre d'individus (prédiction 1)	
count_second	Numérique — Nombre d'individus (prédiction 2)	
seq_first	Numérique — Nb d'images confirmant prédiction 1	
seq_second	Numérique — Nb d'images confirmant prédiction 2	

Comparatif des modèles testés sur Mont_Blanc

Site	Date	Détecteur	Images	Prédictions	Indiv.
Mont Blanc	13/12/24	DeepFaune	1 212 980	116 277	28
Mont Blanc	16/12/24	MDV6	1 212 980	116 144	27
Bauges	01/03/25	MDV5	32 870	5 956	22

2.2.2 Analyse par attribut

2.2.2.1 Attribut : Identifiant

Colonnes traitées : **[Camera_trap]**

2.2.2.1.1 Informations générales Le dossier Mont_Blanc contient **49 caméras uniques**. Les identifiants encodent le nom du secteur, l'altitude et l'orientation géographique.

- Exemples : `loriaz1900Ouest`, `peclerey1600Nord`, `planAig2200Sud`
- Format : chaîne de caractères combinant toponyme + altitude + orientation.

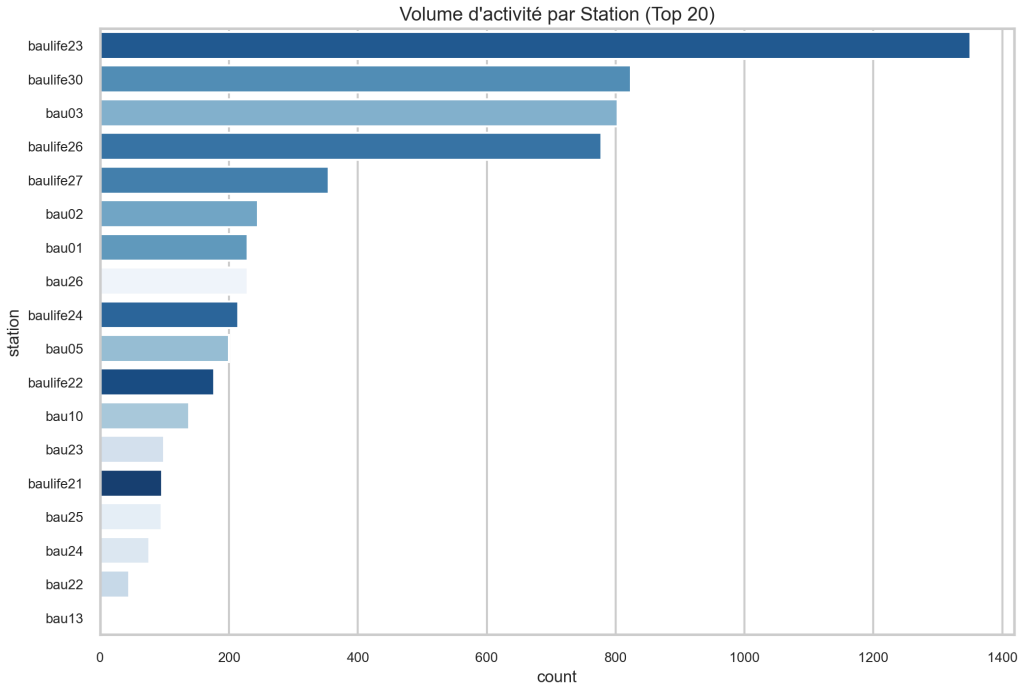

FIGURE 2.6 – Volume d'activité par station (Top 20)

2.2.2.1.2 Problèmes de qualité L'analyse croisée avec le fichier `TousPiegesPhoto.shp` révèle une répartition inégale :

- **Caméras incluses :** Secteurs de Loriaz, Peclerey et PlanAig.
- **Caméras orphelines :** Une partie des capteurs est située en dehors de tout périmètre CREA défini, nécessitant une règle de gestion spécifique lors de l'intégration.

2.2.2.2 Attribut : Temporel

Colonnes traitées : **[Date]**

2.2.2.2.1 Informations générales

- **Format :** ISO 8601 — `AAAA-MM-JJ HH:MM:SS`
- **Plage temporelle :** Du `01/01/2017` au `03/12/2024` soit **2 892 jours**.
- La colonne est complète : **0% de valeurs manquantes**.

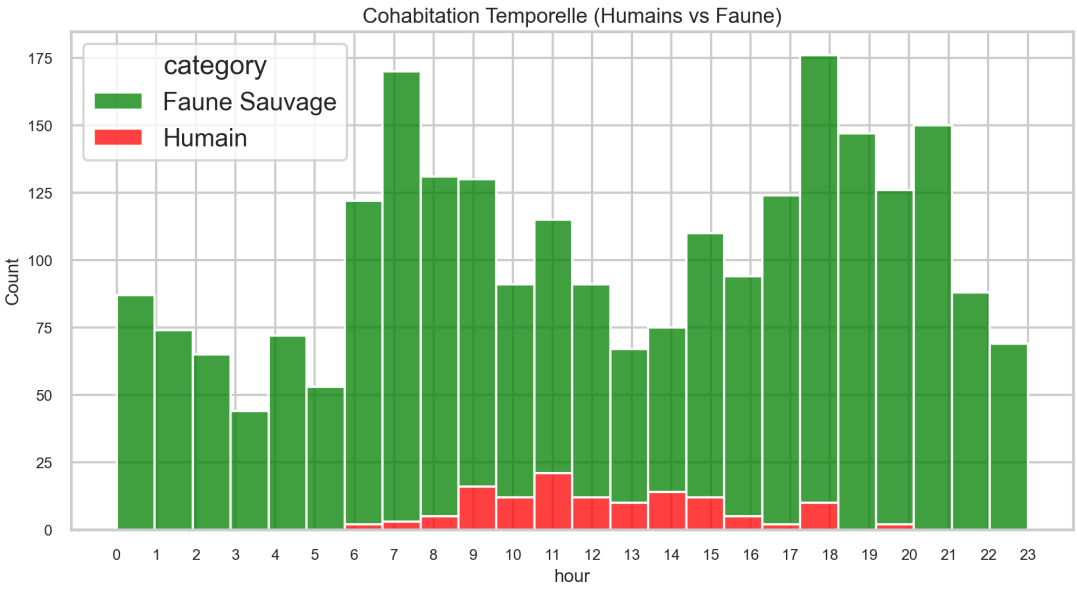

FIGURE 2.7 – Distribution horaire des détections : Faune Sauvage vs Humain

Le graphique montre une répartition claire des activités sur 24 heures :

— **Activité Humaine (Rouge) :** Exclusivement diurne, concentrée entre 07h00 et 18h00, avec un pic notable en fin de matinée (11h).

— **Faune Sauvage (Vert) :** Active toute la journée, mais surtout le matin et le soir, évitant les moments de forte présence humaine.

2.2.2.2.2 Problèmes de qualité Le pic d'activité humaine à 11h (probablement 13h en heure locale) suggère un **possible décalage UTC** / **heure locale** dans l'enregistrement des timestamps.

2.2.2.3 Attribut : Prédiction

Colonnes traitées : **[prediction_first, prediction_second]**

2.2.2.3.1 Informations générales Le modèle MDV6 identifie **26 classes** pour le Mont-Blanc (28 pour DeepFaune).

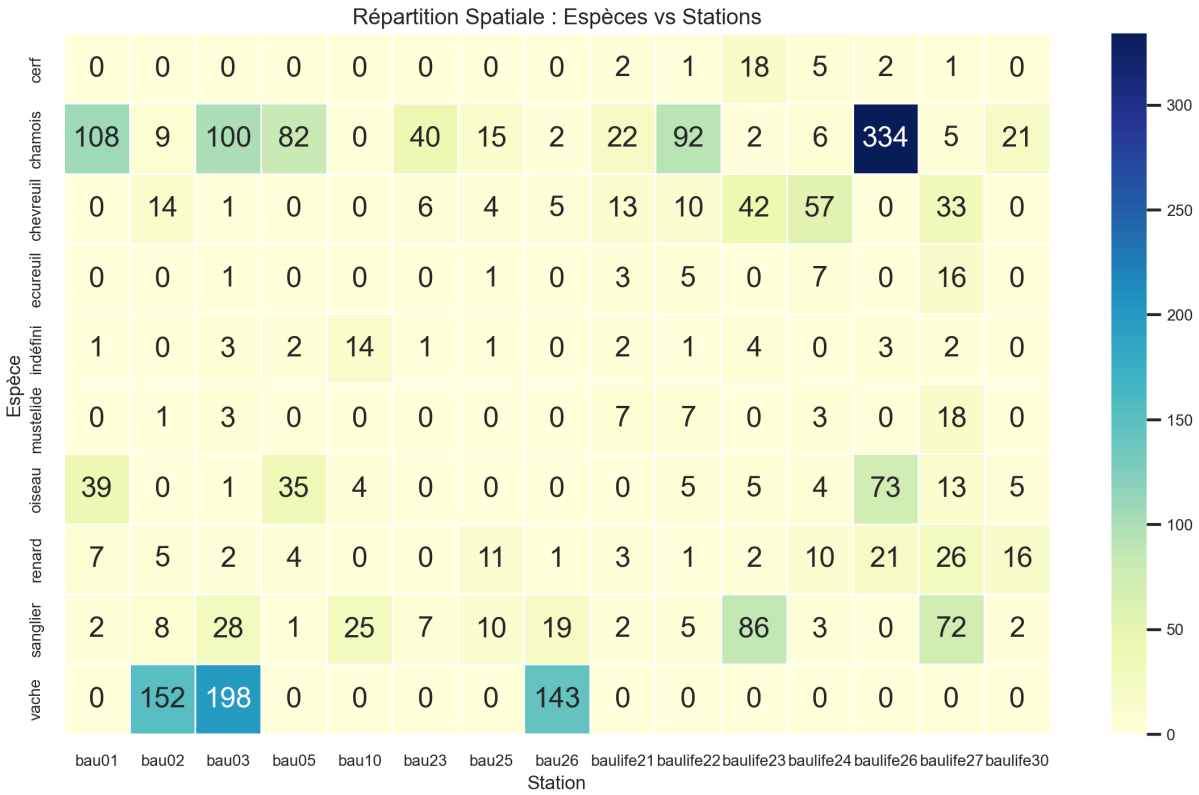

FIGURE 2.8 – Matrice de répartition : Espèces vs Stations

Observations issues de la Heatmap :

— Les **Vaches** sont massivement concentrées sur `bau02`, `bau03` et `bau26` (zones de pâturage).

— Le **Chamois** est l'espèce la plus ubiquiste, présente sur la quasi-totalité des stations, avec un point chaud sur `baulife24`.

2.2.2.3.2 Problèmes de qualité

— **Spécifiques Mont-Blanc (MDV6) :** `lynx`, `genette`, `daim`, `chevre`, `vehicule`.

— **Cas isolé DeepFaune uniquement :** `herisson` absent de MDV6.

— **Classes non-biologiques :** `vehicule` et `vide` doivent être traitées séparément pour ne pas polluer les calculs de biodiversité.

2.2.2.4 Attribut : Comptage

Colonnes traitées : **[count_first, count_second]**

2.2.2.4.1 Informations générales

— **count_first :** 22 valeurs distinctes pour le Mont-Blanc.

— **count_second :** 5 valeurs distinctes. Absent lorsqu'il n'y a pas de prédiction secondaire.

2.2.2.4.2 Problèmes de qualité Même problématique que pour les Bauges : **count_second** contient des valeurs manquantes lorsque la prédiction secondaire est `vide`.

2.2.2.5 Attribut : Séquence

Colonnes traitées : **[seq_first, seq_second]**

2.2.2.5.1 Informations générales

- **seq_first :** Valeur maximale pour Mont-Blanc : **60 images**.
- **seq_second :** Absent si pas de second vote.

Les équidés et les vaches génèrent des séquences très longues (> 7 images/individu). Les prédateurs (Loup, Renard) traversent le champ rapidement (environ 4 images).

2.2.2.5.2 Problèmes de qualité

- **Déséquilibre de charge :** La station `baulife23` enregistre un volume exceptionnel (> 1300 séquences), soit près de 3 fois la moyenne.
- **Séquences longues :** Risque de doublons pour les animaux stationnaires (Vaches, Équidés).

3 | Synthèse des Problèmes de Qualité

3.1 Attribut : Identifiant

Colonnes concernées : **[Camera_trap]**

3.1.1 Hétérogénéité des noms entre Bauges et Mont_Blanc

Les deux dossiers utilisent des conventions de nommage incompatibles :

Zone	Exemples d'identifiants	Format
Bauges	bau02, bau26, baulife23	Préfixe court + numéro
Mont_Blanc	loriaz1900Ouest, peclerey1600Nord	Toponyme + altitude + orientation

Une jointure directe entre les deux sources est **impossible** sans table de mapping intermédiaire.

3.1.2 Recommandation ETL

Recommandation ETL — Camera_trap

- Créer une table de référence `REF_CAMERAS` contenant : identifiant normalisé, zone (Bauges / Mont_Blanc), coordonnées GPS (si disponibles) et secteur d'appartenance (Loriaz, Peclerey, etc.).
- Ajouter une colonne `zone` lors de l'intégration pour distinguer les deux sources.

3.2 Attribut : Localisation

Colonnes concernées : **[Latitude, Longitude]**

3.2.1 Coordonnées manquantes pour les Bauges

Aucune coordonnée GPS précise n'est disponible pour les 18 caméras des Bauges. Seuls les **toponymes** (noms des stations) sont fournis dans les fichiers sources. Il est impossible de situer exactement les caméras sur la carte sans table de correspondance externe.

3.2.2 Caméras orphelines (hors périmètre CREA)

Pour le Mont-Blanc, une partie des capteurs est située **en dehors de tout périmètre CREA défini**, notamment hors des secteurs Loriaz, Peclerey et PlanAig. Ces caméras nécessitent une règle de gestion spécifique lors de l'intégration.

3.2.3 Recommandation ETL

Recommandation ETL — Localisation

- **Bauges :** Tenter une jointure sur le fichier Shapefile du PNR (Corine Land Cover ou Theia OSO) pour récupérer les coordonnées. Si impossible, laisser en `NULL` et le signaler dans `REF_CAMERAS`.
- **Mont_Blanc :** Définir une règle de gestion pour les caméras orphelines (les rattacher au périmètre le plus proche ou créer une zone `HORS_PERIMETRE`).

3.3 Attribut : Temporel

Colonnes concernées : **[Date]**

3.3.1 Fuseaux horaires (UTC vs heure locale)

Le fuseau horaire utilisé lors de l'enregistrement n'est pas documenté dans les métadonnées des deux dossiers. Le pic d'activité humaine détecté à 11h dans les données Mont-Blanc (probablement 13h en heure locale française) suggère un **enregistrement en UTC** avec un décalage de +2h en été.

3.3.2 Recommandation ETL

Recommandation ETL — Date

- Vérifier la configuration des boîtiers (UTC ou heure locale) auprès du CREA avant intégration.
- Standardiser toutes les dates en **UTC** lors de l'intégration.
- Ajouter une colonne `date_local` pour les analyses métier nécessitant l'heure locale.
- Pour les analyses purement biodiversité, créer une vue filtrant les plages horaires à forte présence humaine (07h–18h).

3.4 Attribut : Prédiction

Colonnes concernées : **[prediction_first, prediction_second]**

3.4.1 Hétérogénéité des taxonomies entre modèles

Socle Commun (22 classes — Interopérabilité Immédiate)

Ces données peuvent être intégrées sans transformation majeure :

- *Ongulés :* Bouquetin, Cerf, Chamois, Chevreuil, Sanglier, Vache, Mouton, Équidé.
- *Carnivores :* Loup, Renard, Chien, Blaireau, Mustélidé, Chat.
- *Petits Mammifères :* Marmotte, Écureuil, Lièvre, Micromammifère.
- *Autres :* Humain, Oiseau, Vide, Indéfini.

Divergences (À traiter)

- **Spécifiques Mont-Blanc (MDV6) :** `lynx`, `genette`, `daim`, `chevre`, `vehicule`.
- **Cas isolé DeepFaune uniquement :** `herisson` (absent des prédictions MDV6).

3.4.2 Classes non-biologiques

Les classes `vehicule` (MDV6) et `vide` ne représentent pas des espèces animales. Les intégrer sans distinction risque de polluer les calculs de biodiversité (richesse spécifique, indices de présence).

3.4.3 Recommandation ETL

Recommandation ETL — Prédiction

- Créer une table `REF_TAXONOMY` pour normaliser les labels entre modèles.
- Ajouter un flag `is_biological` (True/False).
- Intégrer une colonne `quality_flag` :
  - Si `confidence_score` < 0.7 → Flag `TO_VERIFY`.
  - Si `prediction_second` = `vide` → Ignorer la seconde prédiction.
- Mapper `chevre` / `bouquetin` vers une famille standardisée si nécessaire.
- Décider du sort de `herisson` : garder par défaut.

3.5 Attribut : Comptage

Colonnes concernées : **[count_first, count_second]**

3.5.1 Valeurs manquantes sur count_second

count_second est absent lorsqu'il n'y a pas de prédiction secondaire. Il est important de distinguer deux cas :

- **NULL fonctionnel :** Absence réelle de seconde détection (pas d'ambiguïté dans la séquence).
- **NULL parasite :** Donnée non renseignée par erreur technique.

3.5.2 Recommandation ETL

Recommandation ETL — Comptage

- Remplacer les `NULL` de `count_second` par **0** lorsque `prediction_second` = `vide`.
- Conserver `NULL` uniquement si `prediction_second` est une espèce animale réelle (indique une vraie ambiguïté de détection).

3.6 Attribut : Séquence

Colonnes concernées : **[seq_first, seq_second]**

3.6.1 Séquences anormalement longues (animaux stationnaires)

Les animaux stationnaires (Vaches, Équidés) génèrent de multiples séquences consécutives pour le même événement d'observation, créant un risque de **double comptage** dans les analyses de fréquentation.

Alerte Performance ETL

Le déséquilibre des volumes (Skewness) peut impacter les performances de chargement. La station `baulife23` représente à elle seule près de 3 fois la moyenne en volume de séquences.
Recommandation : Utiliser un partitionnement composite **(Date + Station)** plutôt qu'un partitionnement uniquement par Station.

3.6.2 Recommandation ETL

Recommandation ETL — Séquence

Implémenter une logique de **sessionisation** dans l'ETL :

- Si deux séquences de la **même espèce** sur la **même caméra** sont séparées de moins de **1 minute** → les fusionner en un seul événement *Observation*.
- Au-delà de deux prédictions concurrentes, les résultats marginaux sont ignorés (comportement natif de DeepFaune).